



EST160 - Aula 01

Lucas Sousa

14 de Agosto de 2026

Conteúdos

Introdução

O Tidyverse

Apresentação de dados

Boas práticas

Descrição da Disciplina


Introdução

Na ciência de dados, geralmente lidamos com **grande volume de dados**, que nem sempre estão organizados.

É importante estabelecermos uma estrutura de trabalho, o que chamamos de *workflow*.

O modelo mais comum é apresentado por Wickham (2014), que dá diretrizes de organização de dados, de modo a facilitar outras etapas do trabalho na área.

Ciclo de Trabalho da Ciência de Dados



Introdução

Nesse trabalho precisamos

- Ter uma visão sóbria sobre todas as etapas que precisaremos seguir;
- Entender que tipo de informação podemos extrair dos dados;
- Apresentar os dados da melhor forma possível, conforme nosso objetivo e público-alvo;

Ferramentas

Para atingir nosso objetivo, temos diversas **ferramentas** possíveis:

R, Python, SAS, SQL, Matlab, Stata, Aplicações de BI, Julia, entre outras

Ferramentas

Para atingir nosso objetivo, temos diversas **ferramentas** possíveis:

R, Python, SAS, SQL, Matlab, Stata, Aplicações de BI, Julia, entre outras

Devemos desenvolver competências e habilidades **independente** da ferramenta utilizada

Por que o R?

Por que o R?

- ▶ É um projeto aberto;

Por que o R?

- ▶ É um projeto aberto;
- ▶ Curva de aprendizado bastante amigável, sendo muito fácil de se aprender;

Por que o R?

- ▶ É um projeto aberto;
- ▶ Curva de aprendizado bastante amigável, sendo muito fácil de se aprender;
- ▶ Enorme quantidade de tutoriais e ajuda disponíveis gratuitamente na internet;

Por que o R?

- ▶ É um projeto aberto;
- ▶ Curva de aprendizado bastante amigável, sendo muito fácil de se aprender;
- ▶ Enorme quantidade de tutoriais e ajuda disponíveis gratuitamente na internet;
- ▶ É excelente para criar rotinas e sistematizar tarefas repetitivas;

Por que o R?

- ▶ É um projeto aberto;
- ▶ Curva de aprendizado bastante amigável, sendo muito fácil de se aprender;
- ▶ Enorme quantidade de tutoriais e ajuda disponíveis gratuitamente na internet;
- ▶ É excelente para criar rotinas e sistematizar tarefas repetitivas;
- ▶ Amplamente utilizado pela comunidade acadêmica e pelo mercado;

Por que o R?

- ▶ É um projeto aberto;
- ▶ Curva de aprendizado bastante amigável, sendo muito fácil de se aprender;
- ▶ Enorme quantidade de tutoriais e ajuda disponíveis gratuitamente na internet;
- ▶ É excelente para criar rotinas e sistematizar tarefas repetitivas;
- ▶ Amplamente utilizado pela comunidade acadêmica e pelo mercado;
- ▶ Quantidade enorme de pacotes, para diversos tipos de necessidades;

Por que o R?

- ▶ É um projeto aberto;
- ▶ Curva de aprendizado bastante amigável, sendo muito fácil de se aprender;
- ▶ Enorme quantidade de tutoriais e ajuda disponíveis gratuitamente na internet;
- ▶ É excelente para criar rotinas e sistematizar tarefas repetitivas;
- ▶ Amplamente utilizado pela comunidade acadêmica e pelo mercado;
- ▶ Quantidade enorme de pacotes, para diversos tipos de necessidades;
- ▶ Ótima ferramenta para criar relatórios e gráficos;

O RStudio

RStudio é uma IDE (Integrated Development Environment) que nos ajuda a realizar nossas atividades utilizando a linguagem R


RStudio é a IDE mais utilizada para se trabalhar com o R, mas essa linguagem pode ser utilizada em outros ambientes

O RStudio

- 1. Editor de Código:** No editor de código, você poderá escrever e editar os scripts.
- 2. Console:** É no console que o R mostrará a maioria dos resultados dos comandos. Também é possível escrever os comandos diretamente no console, sem o uso do editor de código.
- 3. Environment e History:** No Environment ficarão guardados todos os objetos que forem criados na sessão do R.
- 4. Files, Plots, Packages, Help e Viewer:** Nesta janela, estão várias funcionalidades do RStudio.

RStudio

1. Editor de Código
2. Console
3. Ambiente e Histórico
4. Arquivos, Plots, Packages, Help e Viewer



Tidyverse

O Tidyverse é uma **coleção de pacotes do R**, desenhados para atuarem no *workflow* da ciência de dados.



Uma vez carregado, esse pacote disponibiliza todo o conjunto de ferramentas de outros pacotes importantes

Tidyverse



Tidyverse

Remember that they may need to be updated!

Use `tidyverse_update()` to check updates

Other Packages:

```
install.packages(c("arrow", "babynames", "curl", "duckdb",  
"gapminder", "ggrepel", "ggribbles", "ggthemes", "hexbin",  
"janitor", "Lahman", "leaflet", "maps", "nycflights13",  
"openxlsx", "palmerpenguins", "repurrrsive", "tidymodels",  
"writexl"))
```

Anatomia do Tidyverse

readr - importação



- Leitura de dados tabulares: csv, tsv, fwf
- Recursos “inteligentes” que determinam tipo de variável
Ex: importar campos de datas como datas
- Documentação: <https://readr.tidyverse.org/>.

Anatomia do Tidyverse

forcats - manipulação



- Para manipulação de variáveis categóricas/fatores.
- Renomear, reordenar, transformar, aglutinar.
- Documentação: <https://forcats.tidyverse.org/>.

Anatomia do Tidyverse


`stringr` - manipulação



- Recursos coesos construídos para manipulação de strings.
- Feito sobre o stringi.
- Documentação: <https://stringr.tidyverse.org/>.

Anatomia do Tidyverse

tidyr - organização



- Suporte para criação de dados no formato tidy (tabular)
- Documentação: <https://tidyr.tidyverse.org/>.

Anatomia do Tidyverse


dplyr - transformação



- Oferece uma gramática extensa pra manipulação de dados
- Operações de split-apply-combine.
- Na maior parte da manipulação é usado o dplyr.
- Documentação: <https://dplyr.tidyverse.org/>.

Anatomia do Tidyverse

ggplot2 - visualização



- Criação de gráficos baseado no The Grammar of Graphics (Wilkinson, 2011)
- Claro mapeamento das variáveis do BD em variáveis visuais e construção baseada em camadas
- Documentação: <https://ggplot2.tidyverse.org/>

Anatomia do Tidyverse

tibble - tabulação



- Uma reimplementação do data.frame com muitas melhorias
- Documentação: <https://tibble.tidyverse.org/>.

Anatomia do Tidyverse

`purrr` - programação funcional



- Recursos para programação funcional
- Funções que aplicam funções em lote varrendo objetos: vetores, listas, etc.
- Documentação: <https://purrr.tidyverse.org/>.

Anatomia do Tidyverso

lubridate - tempo e data



- Conjunto de funções para trabalhar com datas e tempo, melhorando o suporte do R para estes casos

Documentação: <https://lubridate.tidyverse.org/>

Filosofia Tidy

A ideia trazida por Wickham (2014) foi uma forma padronizada de organização dos dados de modo a facilitar nosso trabalho de análise de dados.

Filosofia Tidy

A ideia trazida por Wickham (2014) foi uma forma padronizada de organização dos dados de modo a facilitar nosso trabalho de análise de dados.

- Uma observação por linha;

Filosofia Tidy

A ideia trazida por Wickham (2014) foi uma forma padronizada de organização dos dados de modo a facilitar nosso trabalho de análise de dados.

- Uma observação por linha;
- Uma variável por coluna;

Filosofia Tidy

A ideia trazida por Wickham (2014) foi uma forma padronizada de organização dos dados de modo a facilitar nosso trabalho de análise de dados.

- Uma observação por linha;
- Uma variável por coluna;
- Um valor por célula.

Filosofia Tidy

A ideia trazida por Wickham (2014) foi uma forma padronizada de organização dos dados de modo a facilitar nosso trabalho de análise de dados.

- Uma observação por linha;
- Uma variável por coluna;
- Um valor por célula.

Também utilizamos **verbos coesos** (select, filter, mutate, summarise, etc) e pipelines para legibilidade.

Filosofia Tidy

Table: Exemplo de dados do conjunto `flights` no pacote `nycflights13`

year	month	day	dep_time	arr_time	carrier	origin	dest
2013	1	1	517	830	UA	EWR	IAH
2013	1	1	533	850	UA	LGA	IAH
2013	1	1	542	923	AA	JFK	MIA
2013	1	1	544	1004	B6	JFK	BQN
2013	1	1	554	812	DL	LGA	ATL
2013	1	1	555	833	B6	EWR	BQN
2013	1	1	557	709	EV	LGA	IAD
2013	1	1	557	838	B6	JFK	MCO
2013	1	1	558	753	AA	EWR	ORD
2013	1	1	558	849	UA	LGA	IAH

Erros Comuns

- ▶ Títulos das colunas são **valores**, não nomes de variáveis;

Erros Comuns

- ▶ Títulos das colunas são **valores**, não nomes de variáveis;
- ▶ **Múltiplas variáveis** são colocadas em uma coluna;

Erros Comuns

- ▶ Títulos das colunas são **valores**, não nomes de variáveis;
- ▶ **Múltiplas variáveis** são colocadas em uma coluna;
- ▶ Variáveis são armazenadas tanto nas **linhas** como nas **colunas**;

Erros Comuns

- ▶ Títulos das colunas são **valores**, não nomes de variáveis;
- ▶ **Múltiplas variáveis** são colocadas em uma coluna;
- ▶ Variáveis são armazenadas tanto nas **linhas** como nas **colunas**;
- ▶ **Múltiplos** tipos de **unidades** observacionais na mesma tabela;

Erros Comuns

- ▶ Títulos das colunas são **valores**, não nomes de variáveis;
- ▶ **Múltiplas variáveis** são colocadas em uma coluna;
- ▶ Variáveis são armazenadas tanto nas **linhas** como nas **colunas**;
- ▶ **Múltiplos** tipos de **unidades** observacionais na mesma tabela;
- ▶ Uma única unidade observacional armazenada em **múltiplas tabelas**.

Colunas são valores, não nomes de variáveis

religion	< \$10k	\$10–20k	\$20–30k	\$30–40k	\$40–50k	\$50–75k
Agnostic	27	34	60	81	76	137
Atheist	12	27	37	52	35	70
Buddhist	27	21	30	34	33	58
Catholic	418	617	732	670	638	1116
Don't know/refused	15	14	15	11	10	35
Evangelical Prot	575	869	1064	982	881	1486
Hindu	1	9	7	9	11	34
Historically Black Prot	228	244	236	238	197	223
Jehovah's Witness	20	27	24	24	21	30
Jewish	19	19	25	25	30	95

Table: The first ten rows of data on income and religion from the Pew Forum. Three columns, \$75–100k, \$100–150k and > 150k, have been omitted.

Colunas são valores, não nomes de variáveis

religion	income	freq
Agnostic	< \$10k	27
Agnostic	\$10–20k	34
Agnostic	\$20–30k	60
Agnostic	\$30–40k	81
Agnostic	\$40–50k	76
Agnostic	\$50–75k	137
Agnostic	\$75–100k	122
Agnostic	\$100–150k	109
Agnostic	> 150k	84
Agnostic	Don't know/refused	96

Table: The first ten rows of the tidied Pew survey dataset on income and religion. The `column` has been renamed to `income`, and `value` to `freq`.

Mudança

row	a	b	c
A	1	4	7
B	2	5	8
C	3	6	9

(a) Dado bruto

row	column	value
A	a	1
B	a	2
C	a	3
A	b	4
B	b	5
C	b	6
A	c	7
B	c	8
C	c	9

(b) Dado modificado

Outro exemplo

Um uso comum desse formato é para registrar observações regularmente espaçadas no tempo.

Table: The first eight Billboard top hits for 2000. Other columns not shown are `wk4`, `wk5`, ..., `wk75`.

year	artist	track	time	date.entered	wk1	wk2	wk3
2000	2 Pac	Baby Don't Cry	4:22	2000-02-26	87	82	72
2000	2Ge+her	The Hardest Part Of ...	3:15	2000-09-02	91	87	92
2000	3 Doors Down	Kryptonite	3:53	2000-04-08	81	70	68
2000	98°	Give Me Just One Nig...	3:24	2000-08-19	51	39	34
2000	A*Teens	Dancing Queen	3:44	2000-07-08	97	97	96
2000	Aaliyah	I Don't Wanna	4:15	2000-01-29	84	62	51
2000	Aaliyah	Try Again	4:03	2000-03-18	59	53	38
2000	Adams, Yolanda	Open My Heart	5:30	2000-08-26	76	76	74

Outro exemplo

Table: First fifteen rows of the tidied Billboard dataset. The date column does not appear in the original table, but can be computed from `date.entered` and `week`.

year	artist	time	track	date	week	rank
2000	2 Pac	4:22	Baby Don't Cry	2000-02-26	1	87
2000	2 Pac	4:22	Baby Don't Cry	2000-03-04	2	82
2000	2 Pac	4:22	Baby Don't Cry	2000-03-11	3	72
2000	2 Pac	4:22	Baby Don't Cry	2000-03-18	4	77
2000	2 Pac	4:22	Baby Don't Cry	2000-03-25	5	87
2000	2 Pac	4:22	Baby Don't Cry	2000-04-01	6	94
2000	2 Pac	4:22	Baby Don't Cry	2000-04-08	7	99
2000	2Ge+her	3:15	The Hardest Part Of ...	2000-09-02	1	91
2000	2Ge+her	3:15	The Hardest Part Of ...	2000-09-09	2	87
2000	2Ge+her	3:15	The Hardest Part Of ...	2000-09-16	3	92
2000	3 Doors Down	3:53	Kryptonite	2000-04-08	1	81
2000	3 Doors Down	3:53	Kryptonite	2000-04-15	2	70
2000	3 Doors Down	3:53	Kryptonite	2000-04-22	3	68
2000	3 Doors Down	3:53	Kryptonite	2000-04-29	4	67
2000	3 Doors Down	3:53	Kryptonite	2000-05-06	5	66

Múltiplas variáveis em uma coluna

Table: Original TB dataset. Corresponding to each 'm' column for males, there is also an 'f' column for females, f1524, f2534 and so on. These are not shown to conserve space. **Note the mixture of 0s and missing values (—).** This is due to the data collection process and the distinction is important for this dataset.

country	year	m014	m1524	m2534	m3544	m4554	m5564	m65	mu	f014
AD	2000	0	0	1	0	0	0	0	—	—
AE	2000	2	4	4	6	5	12	10	—	3
AF	2000	52	228	183	149	129	94	80	—	93
AG	2000	0	0	0	0	0	0	1	—	1
AL	2000	2	19	21	14	24	19	16	—	3
AM	2000	2	152	130	131	63	26	21	—	1
AN	2000	0	0	1	2	0	0	0	—	0
AO	2000	186	999	1003	912	482	312	194	—	247
AR	2000	97	278	594	402	419	368	330	—	121
AS	2000	—	—	—	—	1	1	—	—	—

Múltiplas variáveis na mesma coluna

country	year	column	cases
AD	2000	m014	0
AD	2000	m1524	0
AD	2000	m2534	1
AD	2000	m3544	0
AD	2000	m4554	0
AD	2000	m5564	0
AD	2000	m65	0
AE	2000	m014	2
AE	2000	m1524	4
AE	2000	m2534	4
AE	2000	m3544	6
AE	2000	m4554	5
AE	2000	m5564	12
AE	2000	m65	10
AE	2000	f014	3

(a) Molten data

country	year	sex	age	cases
AD	2000	m	0–14	0
AD	2000	m	15–24	0
AD	2000	m	25–34	1
AD	2000	m	35–44	0
AD	2000	m	45–54	0
AD	2000	m	55–64	0
AD	2000	m	65+	0
AE	2000	m	0–14	2
AE	2000	m	15–24	4
AE	2000	m	25–34	4
AE	2000	m	35–44	6
AE	2000	m	45–54	5
AE	2000	m	55–64	12
AE	2000	m	65+	10
AE	2000	f	0–14	3

(b) Tidy data

Table: Tidying the TB dataset requires first melting, and then splitting the `column` column into two variables: **sex** and **age**.

Variáveis nas linhas e nas colunas

id	year	month	element	d1	d2	d3	d4	d5	d6	d7	d8
MX17004	2010	1	tmax	—	—	—	—	—	—	—	—
MX17004	2010	1	tmin	—	—	—	—	—	—	—	—
MX17004	2010	2	tmax	—	27.3	24.1	—	—	—	—	—
MX17004	2010	2	tmin	—	14.4	14.4	—	—	—	—	—
MX17004	2010	3	tmax	—	—	—	—	32.1	—	—	—
MX17004	2010	3	tmin	—	—	—	—	14.2	—	—	—
MX17004	2010	4	tmax	—	—	—	—	—	—	—	—
MX17004	2010	4	tmin	—	—	—	—	—	—	—	—
MX17004	2010	5	tmax	—	—	—	—	—	—	—	—
MX17004	2010	5	tmin	—	—	—	—	—	—	—	—

Table: Original weather dataset. There is a column for each possible day in the month. Columns d9 to d31 have been omitted to conserve space.

Variáveis nas linhas e nas colunas

id	date	element	value
MX17004	2010-01-30	tmax	27.8
MX17004	2010-01-30	tmin	14.5
MX17004	2010-02-02	tmax	27.3
MX17004	2010-02-02	tmin	14.4
MX17004	2010-02-03	tmax	24.1
MX17004	2010-02-03	tmin	14.4
MX17004	2010-02-11	tmax	29.7
MX17004	2010-02-11	tmin	13.4
MX17004	2010-02-23	tmax	29.9
MX17004	2010-02-23	tmin	10.7

(a) Molten data

id	date	tmax	tmin
MX17004	2010-01-30	27.8	14.5
MX17004	2010-02-02	27.3	14.4
MX17004	2010-02-03	24.1	14.4
MX17004	2010-02-11	29.7	13.4
MX17004	2010-02-23	29.9	10.7
MX17004	2010-03-05	32.1	14.2
MX17004	2010-03-10	34.5	16.8
MX17004	2010-03-16	31.1	17.6
MX17004	2010-04-27	36.3	16.7
MX17004	2010-05-27	33.2	18.2

(b) Tidy data

Table: (a) Molten weather dataset. Missing values are dropped to conserve space. (b) Tidy weather dataset. Each row represents the meteorological measurements for a single day. There are two measured variables, minimum (tmin) and maximum (tmax) temperature; all other variables are fixed.

Múltiplos tipos na mesma tabela

- Metadados das músicas
- Medição semanal dos ranks

year	artist	time	track	date	week	rank
2000	2 Pac	4:22	Baby Don't Cry	2000-02-26	1	87
2000	2 Pac	4:22	Baby Don't Cry	2000-03-04	2	82
2000	2 Pac	4:22	Baby Don't Cry	2000-03-11	3	72
2000	2 Pac	4:22	Baby Don't Cry	2000-03-18	4	77
2000	2 Pac	4:22	Baby Don't Cry	2000-03-25	5	87
2000	2 Pac	4:22	Baby Don't Cry	2000-04-01	6	94
2000	2 Pac	4:22	Baby Don't Cry	2000-04-08	7	99
2000	2Ge+her	3:15	The Hardest Part Of ...	2000-09-02	1	91
2000	2Ge+her	3:15	The Hardest Part Of ...	2000-09-09	2	87
2000	2Ge+her	3:15	The Hardest Part Of ...	2000-09-16	3	92
2000	3 Doors Down	3:53	Kryptonite	2000-04-08	1	81
2000	3 Doors Down	3:53	Kryptonite	2000-04-15	2	70
2000	3 Doors Down	3:53	Kryptonite	2000-04-22	3	68
2000	3 Doors Down	3:53	Kryptonite	2000-04-29	4	67
2000	3 Doors Down	3:53	Kryptonite	2000-05-06	5	66

Temos que repetir os metadados em toda a medição semanal, e trocas de nomes/typos podem gerar inconsistência.

Múltiplos tipos na mesma tabela

id	artist	track	time	id	date	rank
1	2 Pac	Baby Don't Cry	4:22	1	2000-02-26	87
2	2Ge+her	The Hardest Part Of ...	3:15	1	2000-03-04	82
3	3 Doors Down	Kryptonite	3:53	1	2000-03-11	72
4	3 Doors Down	Loser	4:24	1	2000-03-18	77
5	504 Boyz	Wobble Wobble	3:35	1	2000-03-25	87
6	98°	Give Me Just One Nig...	3:24	1	2000-04-01	94
7	A*Teens	Dancing Queen	3:44	1	2000-04-08	99
8	Aaliyah	I Don't Wanna	4:15	2	2000-09-02	91
9	Aaliyah	Try Again	4:03	2	2000-09-09	87
10	Adams, Yolanda	Open My Heart	5:30	2	2000-09-16	92
11	Adkins, Trace	More	3:05	3	2000-04-08	81
12	Aguilera, Christina	Come On Over Baby	3:38	3	2000-04-15	70
13	Aguilera, Christina	I Turn To You	4:00	3	2000-04-22	68
14	Aguilera, Christina	What A Girl Wants	3:18	3	2000-04-29	67
15	Alice DeeJay	Better Off Alone	6:50	3	2000-05-06	66

Apresentação dos dados

Parte do curso é destinado a **visualização de dados**. Uma tarefa importante é encontrar uma representação adequada para a informação.

Apresentação dos dados

Parte do curso é destinado a **visualização de dados**. Uma tarefa importante é encontrar uma representação adequada para a informação.

Devemos entender o **contexto** dos dados, entender nosso **público-alvo** e escolher uma representação adequada.

Apresentação dos dados

Parte do curso é destinado a **visualização de dados**. Uma tarefa importante é encontrar uma representação adequada para a informação.

Devemos entender o **contexto** dos dados, entender nosso **público-alvo** e escolher uma representação adequada.

Pensar na visualização **não é** uma tarefa **natural** para todo mundo, então devemos nos treinar (Knafllic, 2019)

Exemplo – Gráfico de Pizza

Participação no mercado de fornecedores




FIGURA 2.21 Gráfico de pizza

Exemplo – Gráfico de Pizza

Participação no mercado de fornecedores






FIGURA 2.21 Gráfico de pizza

Exemplo – Gráfico de Venn



Exemplo – UpSet Plot



Escolha do gráfico

Lembrem-se como é fácil **perder informação** ao aplicarmos medidas resumo os dados;

Escolha do gráfico



Lembrem-se como é fácil **perder informação** ao aplicarmos medidas resumo os dados;

Também podemos deixar de transmitir informação com uma visualização que não seja adequada.

Escolha do gráfico

Lembrem-se como é fácil **perder informação** ao aplicarmos medidas resumo os dados;

Também podemos deixar de transmitir informação com uma visualização que não seja adequada.



Boas práticas

- ▶ Mantenha os projetos organizados

Boas práticas

- ▶ Mantenha os projetos organizados
- ▶ Comente seu código

Boas práticas

- ▶ Mantenha os projetos organizados
- ▶ Comente seu código
- ▶ `snake_case` para variáveis e funções

Boas práticas

- ▶ Mantenha os projetos organizados
- ▶ Comente seu código
- ▶ `snake_case` para variáveis e funções
- ▶ `esse_pode_ser_um_nome_muito_longo_para_variaveis`

Comentar código

Se o código for pequeno, pode não ser preciso comentar cada etapa

Comentar código

Se o código for pequeno, pode não ser preciso comentar cada etapa

Mas se o código fica mais complexo, os comentários podem salvar bastante tempo (seu e de seus colaboradores)

Comentar código

Se o código for pequeno, pode não ser preciso comentar cada etapa

Mas se o código fica mais complexo, os comentários podem salvar bastante tempo (seu e de seus colaboradores)

Use comentários para explicar o **porquê** do seu código

Curto prazo:

- As tableas e figuras são reproduzíveis a partir do código e dos dados?
- O código realmente faz o que você acha que faz?
- Além disso, está claro porque ele foi feito?

Curto prazo:

- As tableas e figuras são reproduzíveis a partir do código e dos dados?
- O código realmente faz o que você acha que faz?
- Além disso, está claro porque ele foi feito?

Longo prazo:

- O código pode ser usado para outros dados?
- Você pode estender o código para fazer outras coisas?