



EST160 - Aula 05

Lucas Sousa

8 de Setembro de 2026

Conteúdos

Valores Faltantes e Tratamento de NAs

Estratégias de Imputação

Introdução

Dados faltantes são valores não observados que seriam significativos para a análise se fossem observados; em outras palavras, um valor faltante esconde um valor significativo (Little; Rubin, 2019)

Introdução

Dados faltantes são valores não observados que seriam significativos para a análise se fossem observados; em outras palavras, um valor faltante esconde um valor significativo (Little; Rubin, 2019)

Com isso, vamos considerar dados faltantes aqueles que são relevantes para nossa análise.

Geralmente as variáveis do nosso conjunto de dados são relevantes, então precisamos tomar cuidado em descartá-las

Perigos de Ignorar Dados Faltantes

Podemos perder muita informação se decidirmos apenas ignorar dados faltantes

A falta em si pode ser uma informação, mas compreender a relação das variáveis é importante

Simplesmente remover observações desperdiça dados e reduz nossa capacidade de tirar conclusões

Faltas Implícitas vs Explícitas

Faremos a diferenciação entre valores faltantes **implícitos** e **explícitos**.

Faltas Implícitas vs Explícitas

Faremos a diferenciação entre valores faltantes **implícitos** e **explícitos**.

- **Valores faltantes explícitos** aparecem nos nossos dados como NAs
- **Valores faltantes implícitos** simplesmente não estão nos dados

Faltas Implícitas vs Explícitas

Faremos a diferenciação entre valores faltantes **implícitos** e **explícitos**.

- **Valores faltantes explícitos** aparecem nos nossos dados como NAs
- **Valores faltantes implícitos** simplesmente não estão nos dados

```
stocks <- tibble(  
  year   = c(2015, 2015, 2015, 2015, 2016, 2016, 2016),  
  qtr    = c( 1,    2,    3,    4,    2,    3,    4),  
  price  = c(1.88, 0.59, 0.35, NA, 0.92, 0.17, 2.66)  
)
```

Nesse exemplo, temos uma falta explícita para o último trimestre de 2015 e uma falta implícita para o primeiro trimestre de 2016.

Valores Faltantes Explícitos

Segundo Wickham, Grolemund, *et al.* (2017), um uso comum para NAs é não repetir observações em uma tabela.

Nesse caso, podemos interpretar NAs como sendo equivalente às observações anteriores.

```
treatment <- tribble(
  ~ person,      ~ treatment, ~ response,
  "Derrick Whitmore", 1,      7,
  NA,             2,      10,
  NA,             3,      NA,
  "Katherine Burke", 1,      4
)
```

Valores Faltantes Explícitos

Segundo Wickham, Grolemund, *et al.* (2017), um uso comum para NAs é não repetir observações em uma tabela.

Nesse caso, podemos interpretar NAs como sendo equivalente às observações anteriores.

```
treatment <- tribble(
  ~ person,      ~ treatment, ~ response,
  "Derrick Whitmore", 1,      7,
  NA,             2,      10,
  NA,             3,      NA,
  "Katherine Burke", 1,      4
)
```

Nesse caso, podemos por exemplo usar a função `fill()` do pacote `{dplyr}`, que preenche os valores faltantes com as observações anteriores (*last observation carried forward* - locf).

Valores Faltantes Explícitos

```
treatment %>%  
  fill(person)
```

```
#> # A tibble: 4 × 3  
#>   person      treatment response  
#>   <chr>          <dbl>     <dbl>  
#> 1 Derrick Whitmore      1         7  
#> 2 Derrick Whitmore      2        10  
#> 3 Derrick Whitmore      3        NA  
#> 4 Katherine Burke       1         4
```

O argumento `everything()` aplicaria isso a todas as variáveis.

Valores Faltantes Explícitos

Caso um valor faltante represente 0, podemos utilizar a função `coalesce()`, que transformará NAs em 0's.

```
x <- c(1, 4, 5, 7, NA)
coalesce(x, 0)
```

```
#> [1] 1 4 5 7 0
```

Valores Faltantes Explícitos

Se caso contrário um valor represente um NA, podemos por um parâmetro que seja lido como NA, como vimos anteriormente.

Caso o problema seja descoberto depois de ler os dados, podemos utilizar a função `na_if()`

```
x <- c(1, 4, 5, 7, -99)
na_if(x, -99)
```

```
#> [1] 1 4 5 7 NA
```

NaN (Not a Number)

NaN são utilizados para representar uma operação matemática inválida

```
0 / 0
#> [1] NaN
0 * Inf
#> [1] NaN
Inf - Inf
#> [1] NaN
sqrt(-1)
#> Warning in sqrt(-1): NaNs produced
#> [1] NaN
```

NaN (Not a Number)

Geralmente são tratados como NAs, mas em raros casos pode ser importante diferenciá-los.

```
x <- c(NA, NaN)
x * 10
> [1] NA NaN
x == 1
> [1] NA NA
is.na(x)
> [1] TRUE TRUE
is.nan(x)
[1] FALSE TRUE
```

NaN (Not a Number)

Geralmente são tratados como NAs, mas em raros casos pode ser importante diferenciá-los.

```
x <- c(NA, NaN)
x * 10
> [1] NA NaN
x == 1
> [1] NA NA
is.na(x)
> [1] TRUE TRUE
is.nan(x)
[1] FALSE TRUE
```

E se olharmos as classes

```
> class(NA)
[1] "logical"
> class(NaN)
[1] "numeric"
```

Valores Faltantes Implícitos

Quando temos valores faltantes implícitos, uma das estratégias que podemos seguir é pivotar os dados

- Transformar colunas em linhas → `pivot_longer()`
- Transformar linhas em colunas → `pivot_wider()`

Isso fará com que faltas implícitas se mostrem como explícitas, por exemplo.

Valores Faltantes Implícitos

No exemplo anterior, temos uma falta implícita para o primeiro trimestre de 2016

```
stocks <- tibble(  
  year = c(2015, 2015, 2015, 2015, 2016, 2016, 2016),  
  qtr  = c(1, 2, 3, 4, 2, 3, 4),  
  price = c(1.88, 0.59, 0.35, NA, 0.92, 0.17, 2.66)  
)
```

Valores Faltantes Implícitos

No exemplo anterior, temos uma falta implícita para o primeiro trimestre de 2016

```
stocks <- tibble(  
  year = c(2015, 2015, 2015, 2015, 2016, 2016, 2016),  
  qtr  = c(1, 2, 3, 4, 2, 3, 4),  
  price = c(1.88, 0.59, 0.35, NA, 0.92, 0.17, 2.66)  
)
```

```
stocks |>  
pivot_wider(  
  names_from = qtr,  
  values_from = price  
)
```

```
#> # A tibble: 2 × 5  
#>   year `1` `2` `3` `4`  
#>   <dbl> <dbl> <dbl> <dbl> <dbl>  
#> 1 2015 1.88 0.59 0.35 NA  
#> 2 2016 NA 0.92 0.17 2.66
```

Valores Faltantes Implícitos

Podemos utilizar a função `complete()` para gerar valores faltantes explícitos provendo variáveis cujas combinações deveriam existir.

Por exemplo, nesse conjunto de dados, sabemos que deveríamos ter todas as combinações de `year` e `qtr`, então essas variáveis serão nossos parâmetros.

Valores Faltantes Implícitos

Podemos utilizar a função `complete()` para gerar valores faltantes explícitos provendo variáveis cujas combinações deveriam existir.

Por exemplo, nesse conjunto de dados, sabemos que deveríamos ter todas as combinações de `year` e `qtr`, então essas variáveis serão nossos parâmetros.

```
stocks %>%  
  complete(year, qtr)  
#> # A tibble: 8 × 3  
#>   year    qtr return  
#>   <dbl> <dbl>   <dbl>  
#> 1  2015     1   1.88  
#> 2  2015     2   0.59  
#> 3  2015     3   0.35  
#> 4  2015     4    NA  
#> 5  2016     1    NA  
#> 6  2016     2   0.92  
#> #           2 more rows
```

Valores Faltantes Implícitos

Normalmente utilizaremos a função `complete()` com os nomes de variáveis existentes, mas vezes essas variáveis podem estar incompletas também.

Por exemplo, a variável `year` pode não ter todos os anos que sabemos que deveria ter. Nesse caso, podemos fornecer os anos faltantes.

Valores Faltantes Implícitos

Normalmente utilizaremos a função `complete()` com os nomes de variáveis existentes, mas vezes essas variáveis podem estar incompletas também.

Por exemplo, a variável `year` pode não ter todos os anos que sabemos que deveria ter. Nesse caso, podemos fornecer os anos faltantes.

```
stocks |>
  complete(year = 2014:2016, qtr)
#> # A tibble: 12 × 3
#>   year   qtr price
#>   <dbl> <dbl> <dbl>
#> 1 2014     1    NA
#> 2 2014     2    NA
#> 3 2014     3    NA
#> 4 2014     4    NA
#> 5 2015     1  1.88
#> 6 2015     2  0.59
#> #           with 6 more rows
```

Natureza do Dados Faltante

As definições de Little and Rubin (2019) dividem os tipos de dados faltantes em três categorias, a partir de uma interpretação estatística.

- ▶ Dados Faltantes Completamente Aleatórios (MCAR)
- ▶ Dados Faltantes (Condicionalmente) Aleatórios (MAR)
- ▶ Dados Faltantes Não Aleatórios (MNAR)

Dados Faltantes Completamente Aleatórios (MCAR)

Dados MCAR são dados faltantes que não dependem de nenhuma das variáveis do conjunto de dados para não serem observadas (nem da própria variável que apresenta faltas).

Se assumirmos um comportamento aleatório, então isso seria equivalente a **ausência** ocorrer com probabilidade $p \in (0, 1)$ de forma **independente**.

Dados Faltantes (Condicionalmente) Aleatórios (MAR)

Dados MAR são dados faltantes cuja falta depende de outras variáveis do conjunto de dados, mas não da própria variável que apresenta a falta.

Se assumirmos um comportamento aleatório, então isso seria equivalente a **ausência** ocorrer de acordo com uma **probabilidade condicional** que depende de outras variáveis do conjunto de dados.

Dados Faltantes Não Aleatórios (MNAR)

Dados MNAR são dados faltantes cuja falta em uma variável depende da própria variável, mas não das outras variáveis do conjunto de dados.

Se assumirmos um comportamento aleatório, então isso seria equivalente a **ausência** ocorrer de acordo com uma **probabilidade condicional** que depende do valor não observado.

IQ	Job performance ratings			
	Complete	MCAR	MAR	MNAR
78	9	—	—	9
84	13	13	—	13
84	10	—	—	10
85	8	8	—	—
87	7	7	—	—
91	7	7	7	—
92	9	9	9	9
94	9	9	9	9
94	11	11	11	11
96	7	—	7	—
99	7	7	7	—
105	10	10	10	10
105	11	11	11	11
106	15	15	15	15
108	10	10	10	10
112	10	—	10	10
113	12	12	12	12
115	14	14	14	14
118	16	16	16	16
134	12	—	12	12

Job Performance Ratings with MCAR, MAR, and MNAR Missing Values
(Enders, 2022)

Em que caso estamos?

Não é exatamente imediato descobrir de que natureza se trata os tipos de dados faltantes

Se não sabemos exatamente o motivo, vamos fazer **suposições** estatísticas sobre o comportamento. Então é necessário que possamos testar essas suposições.

Testamos suposições estatísticas por meio de **teste de hipóteses**.

Em que caso estamos?

É mais fácil descartar MCAR, onde podemos utilizar o teste de Little (1988) (Little teste para dados MCAR)

No R temos o pacote `{misty}` (documentação aqui), com a função `na.test()`, que realizar esse teste.

Em que caso estamos?



Perfomei o teste para os dados de café Arábica, após remover as colunas vazias e a coluna Notes

Em que caso estamos?



Perfomei o teste para os dados de café Arábica, após remover as colunas vazias e a coluna Notes

Eu ainda precisei

- ▶ Lidar com o fato de que os dados estavam sendo tratados como listas, pois tínhamos valores vistos como NULL quando utilizamos a função `na.test()`
- ▶ Remover a coluna `x1`, que foi criada referente aos índices das observações e estava atrapalhando o teste

Em que caso estamos?

O teste encontrou **141 padrões de falta** e **rejeitou** a hipótese de que os dados são MCAR a um nível de significância de 5% ou 1% (nesse caso o p-valor foi bem pequeno).



```
na.test(arabica)
```

Little's MCAR Test

n	nIncomp	nPattern	X ²	df	p
1312	1181	141	42851.58	4801	0.000

Em que caso estamos?

Eu não verifiquei se ainda assim era adequado performar o teste! Cuidado!

Além disso, esse é um teste populacional. Isso significa que ele não nos indica quais variáveis nos informam a rejeição!

Agora precisamos investigar ainda mais as variáveis entre si.

Em que caso estamos?

Mas ainda temos a questão de verificar se estamos no caso MAR ou MNAR, o que é problemático

Entender se os dados são MAR ou MNAR importa porque isto influencia no **viés** do seu método de imputação.

Pacote {naniar}



Podemos utilizar o pacote `{naniar}` para fazer uma investigação sobre os dados faltantes e levantar algumas hipóteses que podem nos ajudar a decidir o método de imputação.

Esse acaba sendo um trabalho artesanal, que o que fazemos na estatística ao levantar hipóteses a partir de uma análise descritiva.

Pacote {naniar}




As principais funções que utilizaremos são

- ▶ `vis_miss()`: cria uma **shadow matrix** dos dados faltantes;
- ▶ `gg_miss_var()`: mostra quais **variáveis** estão com mais falta
- ▶ `gg_miss_case()`: mostra que **observações** estão com mais falta
- ▶ `gg_miss_upset()`: mostra um **upset plot** com a relação das faltas das variáveis


Dados de Café

Antes de manipular os dados, temos a seguinte shadow matrix com `gg_miss_var()`




Dados de Café

Olhando os NAs pelas variáveis com `gg_miss_var()`




Dados de Café

Olhando os NAs pelas variáveis com `gg_miss_var()` após utilizar `arabica <- janitor::remove_empty(arabica, which = "cols")`



Dados de Café


Olhando as observações que possuem NA com a função `gg_miss_case()`



Dados de Café


Olhando as observações que possuem NA com a função `gg_miss_case()` e removendo a ordenação com

```
gg_miss_case(arabica, order_cases = FALSE)
```




Dados de Café

Olhando a associação em entre falta de variáveis com a função `gg_miss_upset()` (o padrão é 5 variáveis e aumentei para 10)




Dados de Café

Mas a variável com mais faltas é o número do lote. Aumentando um pouco número de variáveis analisadas, temos



Dados de Café

Depois de manipular os dados, temos a seguinte shadow matrix com `gg_miss_var()`



Dados de Café

Nos nossos dados haviam dados não estruturados (como datas em locais aleatórios) que também deveriam ser tratadas como dados faltantes

Isso significa que antes de lidar com as NAs deveríamos realizar um melhor pré-processamento dos dados, não apenas remover variáveis!

Mas em que caso estamos???????

A partir dessa análise inicial, poderíamos investigar melhor a falta das variáveis de interesse e tentar criar **intuição** sobre o tipo de dado faltante;

A partir daí, podemos escolher métodos de imputação e realizar testes de sensibilidades com diferentes suposições, isto é, comparar os resultados de diferentes métodos de imputação.

Estratégias de Imputação

Agora que sabemos que podemos ter dados faltantes e que podemos explorar esses dados, precisamos procurar estratégias para lidar com essa falta.

Nossas opções são:

- ▶ **Imputação:** onde valores são preenchidos no lugar dos dados faltantes;
- ▶ **Omissão:** onde amostras com dados inválidos ou variáveis são descartadas;
- ▶ **Análise:** onde aplicamos métodos que não sejam afetados pelos dados faltantes.

Estratégias de Imputação

Um caso onde poderíamos escolher a **omissão** para realizar a análise seria o caso Dados Faltantes Completamente Aleatórios (MCAR), mas é raro estarmos nesse caso;

Estratégias de Imputação

Um caso onde poderíamos escolher a **omissão** para realizar a análise seria o caso Dados Faltantes Completamente Aleatórios (MCAR), mas é raro estarmos nesse caso;

MAR será uma suposição usual de modelos de imputação, mas não podemos assumir isso sem tomar muito cuidado;

Estratégias de Imputação

Um caso onde poderíamos escolher a **omissão** para realizar a análise seria o caso Dados Faltantes Completamente Aleatórios (MCAR), mas é raro estarmos nesse caso;

MAR será uma suposição usual de modelos de imputação, mas não podemos assumir isso sem tomar muito cuidado;

Além da nossa análise descritiva e exploratória, é importante sabermos de onde os dados vieram e como foram coletados, porque isso pode adicionar informação para nossas decisões.

Van Buuren (2012) é uma boa referência para o assunto. Little and Rubin (2019) é uma referência para um futuro mais técnico.

Estratégias de Imputação

Remoção dos Dados Falantes (Listwise deletion)

Eliminar as **observações** faltantes tem a vantagem da **conveniência**.

Se os dados forem MCAR, a remoção produz estimadores não viesados para média, variância e coeficientes de regressão.

Se os dados são MCAR, a remoção produz erros padrões e níveis de significância que são corretos para o conjunto dos dados reduzidos, mas são geralmente maiores em relação aos dados completos.

Estratégias de Imputação

Remoção dos Dados Falantes

A desvantagem de remover os NAs é que isso é potencialmente um desperdício;

Se o número de variáveis é grande, então não é incomum nos livramos de de mais da metade dos dados originais;

Uma amostra muito menor pode reduzir a nossa capacidade de detectar efeitos de interesse.

Estratégias de Imputação

Remoção dos Dados Falantes

Outras questões

- ▶ Se os dados não forem MCAR, deletar as observações pode provocar muito viés na média e coeficientes de regressão;
- ▶ Apagar as observações pode trazer inconsistências nos relatórios, visto que podemos querer criar subtabelas com diferentes subconjuntos dos dados.

Estratégias de Imputação

Remoção em Pares (Pairwise deletion)

Também conhecida como *available-case analysis* (análise de casos disponíveis), é uma forma de tentar mitigar os problemas da *listwise deletion*

Nesse caso, calculamos as médias e (co)variâncias de todos os dados observados

- A média da variável X é baseada em todos os casos observados nos dados da própria X ;
- A média da variável Y é baseada em todos os casos observados nos dados da própria Y • Para correlação e covariância, são tomados os dados onde X e Y não possuem faltas simultâneas

A partir daí, utilizamos essas informações para realizar alguma análise estatística.

Estratégias de Imputação

Remoção em Pares (Pairwise deletion)

Esse método é simples e parece usar toda informação disponível, o que reduz a questão do desperdício

Se temos dados MCAR, ele produz estimadores consistentes para média, correlação e covariância de acordo com Little and Rubin (2019)

Novamente os estimadores podem ser viesados se os dados não são MCAR

As matrizes de covariância e correlação podem não ser positivas definidas (uma propriedade importantes para muitos procedimentos multivariados que veremos no futuro)

Estratégias de Imputação

Remoção em Pares (Pairwise deletion)

Se os dados forem muito correlacionados, os problemas podem ser mais severos e temos uma questão com o tamanho da amostra e o erro padrão;

Precisamos assumir normalidade aproximada dos dados (outro conceito que veremos no futuro), mas geralmente temos tipos mistos de variáveis

Estratégias de Imputação

Remoção em Pares (Pairwise deletion)

É interessante utilizar toda informação disponível, mas uma análise apropriada da *pairwise matrix* requer técnicas de otimização sofisticadas e fórmulas especiais para calcular erros padrões, o que tira o ponto de sua utilidade (em relação a praticidade)

Esse método funciona melhor se os dados seguem aproximadamente uma normal multivariada, se a correção entre as variáveis é baixa e se a suposição de MCAR é plausível, do contrário não é recomendado.

Estratégias de Imputação

Imputação Pela Média

Uma forma rápida de lidar com os dados faltantes é imputando pela média (ou moda, se os dados forem categóricos)

A imputação pela média distorce a distribuição dos dados de várias formas

Podemos acabar criando coisas como uma distribuição bimodal, o erro padrão pode ser artificialmente reduzido pela média

Estratégias de Imputação

Imputação Pela Média

Esse método é rápido e simples, mas pode subestimar a variância e distorcer relações entre as variáveis

Também irá viesar quase qualquer outro estimador que não seja a própria média, e ainda tratá viés para a média se os dados não forem MCAR

Esse método deve ser utilizado somente como um conserto rápido quando a quantidade de dados faltantes é baixa, e deve ser evitado no geral

Estratégias de Imputação

Imputação Pela Mediana

Os problemas ao utilizar a mediana serão semelhante, mas temos a vantagem dessa medida sofrer menos com a presença de outliers, e podemos considerá-la no lugar da média com os mesmos cuidados anteriores

Se temos distribuições assimétricas, pode ser um caso a se considerar no lugar da média, principalmente se temos uma quantidade menor de dados faltantes

Estratégias de Imputação

Imputação Pela Moda

Para a moda, as vantagens da praticidade serão parecidas, mas também podemos criar diversos problemas em relação a variabilidade e relação das variáveis


Se temos uma categoria muito dominante, então pode ser razoável utilizá-la, porém precisamos tomar cuidado se os dados forem MAR, pois estamos justamente ignorando a relação entre as variáveis

Podemos preferir transformar os NAs em fatores, criando categorias para os dados faltantes, o que evita a exclusão de variáveis

Estratégias de Imputação

Imputação Por Regressão

Regressão é uma técnica comum para estimativa variáveis dependentes



Nesse caso, temos uma equação onde $\mathbf{Y} = \beta_0 + \beta_1 \mathbf{X} + \epsilon$

Queremos encontrar β_0 e β_1 que melhor se ajustam ao modelo, isto é, que melhor aproximam nossos dados.

Estratégias de Imputação

Imputação Por Regressão

Imputação por regressão incorpora informação sobre outras variáveis com a ideia de produzir uma imputação mais inteligente

Nesse caso, a variável que queremos imputar será ajustada como variável dependente de um modelo de regressão que consideramos apropriado

Encontrar o modelo depende do tipo de dados. Podemos por exemplo ter uma relação linear entre as variáveis, mas a relação pode ser quadrática, exponencial, etc.

Estratégias de Imputação

Imputação Por Regressão

Uma questão a ser observada é que podemos ter viés na correlação das nossas variáveis, principalmente se o número de variáveis faltantes aumentar;

Imputação por regressão nos leva a uma estimação não viesada da média sob MCAR.

Se as variáveis explanatórias (as que estamos utilizando para prever a que falta) estiverem completas, isso também nos dá uma estimativa não viesada dos betas β

Além disso, os coeficiente de regressão são não viesados sob a suposição de MAR se os fatores que influenciam a falta são parte do nosso modelo de regressão

Estratégias de Imputação

Imputação Por Regressão

Muita atenção deve ser tomada quando lidamos com esse tipo de imputação. A imputação vai ser mais realista quando a informação faltante está na verdade codificada de outra forma

Van Buuren (2012) destaca que esse é um tipo perigoso de imputação porque pode nos levar a acreditar que temos uma boa previsão

Esse método fortalece artificialmente a relação dos dados e envies a correlação (aumenta). Além disso, a Variabilidade é subestimada

Podemos ter muitos falso positivos e relações espúrias.

Estratégias de Imputação

Last Observation Carried Forward (LOCF) and Baseline Observation Carried Forward (BOCF)

Esses métodos são comuns para dados **longitudinais**, onde temos várias observações do mesmo indivíduo.

LOCF utiliza a última observação do indivíduo e BOCF utiliza a *baseline*, isto é, a primeira.

Por exemplo, podemos querer avaliar um tratamento médico por meses. Com isso, teríamos que ter diversas observações a respeito da mesma pessoa.

Estratégias de Imputação

Last Observation Carried Forward (LOCF) and Baseline Observation Carried Forward (BOCF)

O LOCF é conveniente porque gera uma base de dados completa

Pode ser aplicado com confiança nos casos onde temos certeza que os dados faltantes deveriamos ser administrados como dados longitudinais

Mas LOCF pode gerar viés mesmo sob MCAR, que é a melhor suposição.

Ambos são muito restritos, mas se não queremos supor que um paciente continuou melhorando, por exemplo, utilizaos o BOCF. Não é recomendado que sejam utilizados como primeira abordagem.

Estratégias de Imputação

Estratégias mais avançadas:

- ▶ Multivariate Imputation by Chained Equations (MICE)
- ▶ K-Nearest Neighbors (KNN) Imputation
- ▶ MissForest/Decision Trees
- ▶ Support Vector Machines (SVM)

Referências I



ENDERS, Craig K. **Applied missing data analysis**. [S. l.]: Guilford Publications, 2022.



LITTLE, Roderick JA. A test of missing completely at random for multivariate data with missing values. **Journal of the American statistical Association**, Taylor & Francis, v. 83, n. 404, p. 1198–1202, 1988.



LITTLE, Roderick JA; RUBIN, Donald B. **Statistical analysis with missing data**. [S. l.]: John Wiley & Sons, 2019.



VAN BUUREN, Stef. **Flexible imputation of missing data**. [S. l.]: CRC press Boca Raton, FL, 2012. v. 10.



WICKHAM, Hadley; GROLEMUND, Garrett, *et al.* **R for data science**. [S. l.]: o'reilly Sebastopol, 2017. v. 2.